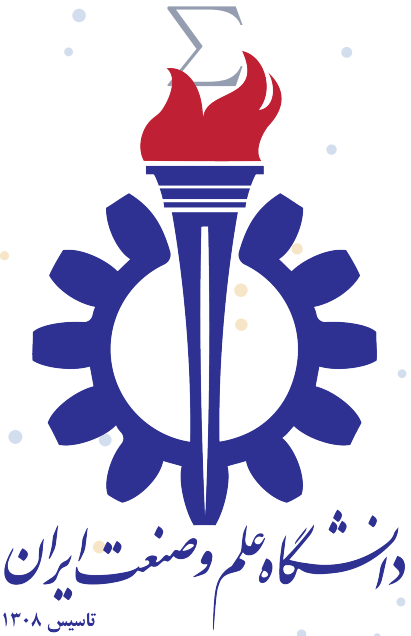


درس داده‌کاوی، مینی‌پروژه ۱

کالبدشکافی داده

اساتید درس	دکتر غیور باغبانی و دکتر سپهر
طراح	رامین بوذرپور
نیم‌سال تحصیلی	نیم‌سال اول ۱۴۰۵-۱۴۰۶
مباحث	فصل‌های ۱، ۲ و ۳
اسلایدهای مرتبط	کل اسلایدهای فصل ۱ تا ۳
تاریخ انتشار	۱۴۰۵/۰۷/۱۷
ددلاین تحویل	۱۴۰۵/۰۷/۲۷
نمره	از ۱۰۰

۱ قوانین کلی

- کار باید به‌صورت انفرادی انجام شود. کدزنی از دیگران یا استفاده از کد آماده‌ی دانشجویان دیگر، بدون ارجاع، تقلب محسوب می‌شود.
- استفاده از ابزارهای هوش مصنوعی (مانند ChatGPT و مشابه آن) ممنوع نیست، به شرط آن‌که میزان و نحوه‌ی استفاده با جزئیات کامل در گزارش ذکر شود. صرف کپی‌کردن خروجی یک ابزار بدون درک و توضیح، تخلف محسوب می‌شود.
- مهلت تأخیر مجاز در طول ترم محدود است (طبق اطلاعیه‌ی رسمی گروه)؛ برای همین از همان ابتدای انتشار پروژه برای تحویل آن برنامه‌ریزی کنید.
- تمدید فقط در شرایط خاص و با هماهنگی تیم دستیار امکان‌پذیر است.
- نمره‌ی نهایی بر اساس سه مورد تعیین می‌شود: درستی و کامل‌بودن کد، کیفیت و شفافیت گزارش، و تعهد به ددلاین اعلام‌شده.

تبصره: در کل ترم ده روز تأخیر مجاز برای دریافت تمام مینی‌پروژه‌ها در اختیار دارید، اما از این سهمیه حداکثر سه روز را می‌توان برای همین یک مینی‌پروژه استفاده کرد. زمان‌بندی این پروژه طوری بسته شده که عملاً جایی برای تأخیر باقی نمی‌ماند؛ برای همین از همان روز اول برای تحویل آن برنامه‌ریزی کنید و درخواست تمدید را به لحظات پایانی موکول نکنید. تمدید نیز فقط در شرایط خاص و استثنایی، و با هماهنگی تیم دستیار، امکان‌پذیر است.

۲ نحوه تحویل و فرمت‌بندی فایل‌ها

تحویل نهایی شامل دو بخش است: کدها (نوت‌بوک یا اسکریپت) و گزارش. هر دو باید در قالب یک فایل زیپ کنار هم قرار بگیرند.

۱.۲ فرمت نام‌گذاری فایل

برای اینکه پیدا کردن و دسته‌بندی تعداد زیادی فایل ساده باشد، همه دانشجویان باید از این الگوی زیر پیروی کنند:

```
[StudentID]_[LastName]_MP[ProjectNumber].zip
```

مثال: `9912345_Entezari_MP1.zip`

داخل زیپ هم همین الگو را دنبال کنید:

- `9912345_Entezari_MP1_Report.pdf`
- `9912345_Entezari_MP1_Code.ipynb` (یا پوشه‌ای از فایل‌های کد، اگر پروژه بیشتر از یک فایل نیاز دارد)

فایلی که این الگو را رعایت نکند، هیچ نمره‌ای به آن تعلق نمی‌گیرد.

۲.۲ محتوای گزارش

- ✓ یک صفحه ابتدایی برای معرفی (لوگوی دانشگاه، نام درس، شماره دانشجویی و نام خود دانشجو)
- ✓ عکس از ورودی‌ها و خروجی‌ها و روند کلی کار
- ✓ توضیح ساده و قابل‌فهم برای هر بخش از کد: چرا این کار انجام شده و چطور به نتیجه رسیده‌اید
- ✓ اگر از روش یا تکنیک خاصی استفاده کردید، حتماً ذکرش کنید
- ✓ مشکلاتی که حین کار با آن‌ها مواجه شدید، به همراه راه‌حلی که پیدا کردید
- ✓ میزان و نحوه دقیق استفاده از هاLLM (اگر استفاده شده)

۳ مینی‌پروژه ۱: کالبدشکافی داده

۱.۳ بخش اول: مجموعه‌داده

۱. فایلی که با آن کار می‌کنید `iran_poi_raw.csv` نام دارد و ۲۹۷,۱۵۲ مکان واقعی در ایران را در خودش جا داده: رستوران، مسجد، مدرسه، بانک، پارک، مطب و مواردی از این دست. این داده از نقشه‌ی OpenStreetMap در برشی که Geofabrik در تاریخ ۱۴۰۴/۰۷/۱۳ منتشر کرده استخراج شده است. حجم فایل نزدیک به ۴۸ مگابایت است و ۲۸ ستون دارد.

۲. این داده را یک سازمان گردآوری نکرده؛ کاربران داوطلب OpenStreetMap از سال ۲۰۰۷ تا امروز آن را وارد کرده‌اند و هیچ کنترل کیفیت مرکزی‌ای روی آن اعمال نشده است. فایل عمداً پاک‌سازی نشده است.

۳. ستون `nearest_hub` نزدیک‌ترین مرکز استان را فقط بر پایه‌ی فاصله‌ی مستقیم جغرافیایی به هر رکورد نسبت می‌دهد، نه مرز اداری واقعی؛ ستون `hub_km` همین فاصله را به کیلومتر نشان می‌دهد. این تقسیم‌بندی رسمی نیست و باید در گزارش همین‌طور معرفی شود.

هر رکورد با `osm_type` و `osm_id` شناسایی می‌شود؛ `version` می‌گوید این مکان چند بار ویرایش شده (رکورد نگه‌داشته‌شده با بیشترین ویرایش، ۵۰ بار دست‌خورده) و `edit_date` تاریخ آخرین تغییرش است. موقعیت جغرافیایی در `lat` و `lon` ذخیره شده، و این‌که این مکان چه نوعی است در `main_key` و `main_value` می‌آید، مثلاً `amenity` برای دسته و `restaurant` برای زیردسته.

نام مکان را سه ستون `name`، `name:fa` و `name:en` نگه می‌دارند، دقیقاً به همان شکلی که کاربر در OSM تایپ کرده است. آدرس در `addr:city`، `addr:street` و `addr:housenumber` آمده، ولی بدون هیچ قاعده‌ی ثابتی وارد شده؛ تلفن، وب‌سایت و ساعت کاری هم در `phone`، `website` و `opening_hours` به همین اندازه آزادند. `capacity` در تئوری ظرفیت مکان را به عدد نشان می‌دهد و `n_tags` تعداد کل برچسب‌های OSM همان رکورد است.

دو ستون آخر را خودمان به داده افزوده‌ایم: `nearest_hub` نزدیک‌ترین مرکز استانی تقریبی هر رکورد را نشان می‌دهد و `hub_km` فاصله تا همان مرکز را به کیلومتر می‌دهد. هر برچسب دیگری از OSM که در هیچ‌کدام از این ستون‌ها جا نشده، در `other_tags` به‌صورت JSON باقی مانده است.

۲.۳ بخش دوم: شرح مسئله

۱.۲.۳ گام اول: شناخت وظایف داده‌کاوی (فصل ۱، ۱۰ نمره)

این سه سوال را در نظر بگیرید: «آیا نوع مکان (`main_value`) را می‌شود فقط از روی اسمش حدس زد؟»، «کدام مناطق جغرافیایی تراکم بیشتری از مکان‌های تفریحی دارند؟» و «کدام رکوردها نسخه‌ی تکراری

یک مکان دیگرند؟». برای هرکدام مشخص کنید زیرمجموعه‌ی کدام وظیفه‌ی داده‌کاوی است (دسته‌بندی، رگرسیون، خوشه‌بندی، قوانین انجمنی یا تشخیص ناهنجاری) و در یکی دو جمله دلیلتان را بنویسید.

۲.۲.۳ گام دوم: نوع ویژگی و آمار پایه (فصل ۲، ۱۰ نمره)

۱. نوع هر یک از ستون‌های `main_key`، `version`، `edit_date`، `lat/lon`، `capacity` و `hub_km` را (اسمی، ترتیبی، فاصله‌ای یا نسبتی) مشخص کنید و برای هرکدام یک جمله دلیل بیاورید.

۲. آمار پایه‌ی دیتاست را گزارش دهید: تعداد کل رکوردها، سهم هرکدام از هفت دسته‌ی `main_key` (amenity, shop, leisure, office, tourism, craft, healthcare)، و درصد مقدار گمشده در هر ستون.

۳. بعضی ستون‌ها مثل `capacity` یا `cuisine` بیش از ۹۵٪ مقدارشان خالی است. توضیح دهید چرا این لزوماً خطای جمع‌آوری داده نیست و چه دلیل دیگری می‌تواند داشته باشد.

۳.۲.۳ گام سوم: کیفیت داده (فصل ۲، ۲۵ نمره)

۱. ستون `addr:city` را باز کنید و ببینید اسم شهرها چقدر به‌هم‌ریخته ثبت شده‌اند. تعداد مقادیر یکتای این ستون را گزارش دهید و دست‌کم چهار شکل نوشتاری متفاوت برای یک شهر واقعی پیدا کنید؛ مثلاً «تهران» و «Tehran» و «شهر تهران» و «tehran»

۲. ببینید چند نام در ستون `name` حرف عربی «ك» یا «ي» دارند، به‌جای معادل فارسی‌شان «ک» و «ی»، و این عدد را گزارش دهید. چرا این نوع نویز مخصوص داده‌ای است که کاربرهای عادی وارد کرده‌اند، نه داده‌ای که یک سازمان با فرمت ثابت تولید کرده؟

۳. ستون `capacity` باید عددی باشد، ولی نیست. مقادیری را که عدد معتبر نیستند استخراج و دسته‌بندی کنید؛ برای مثال عدد منفی، واحد اشتباه (متر مربع به‌جای نفر)، یا حتی اسم یک مکان یا شهر به‌جای عدد. برای هر دسته بنویسید این خطا از کجا می‌تواند آمده باشد.

۴. ده نمونه از ستون `phone` را نشان دهید و فرمت‌هایشان را با هم مقایسه کنید: ارقام فارسی در برابر لاتین، با یا بدون `98+`، با یا بدون فاصله، و شماره‌هایی که حتی کامل هم نیستند. این فرمت‌ها را دسته‌بندی کنید.

۵. مختصات `lat/lon` را تا ۴ رقم اعشار گرد کنید و رکوردهایی پیدا کنید که هم مختصاتشان نزدیک است و هم `main_value` یکسانی دارند. تعدادشان را گزارش دهید و دست‌کم سه نمونه‌ی واقعی بیاورید که به نظرتان یک مکان را دوبار در نقشه ثبت کرده‌اند. این فهرست را برای گام پنجم نگه دارید.

۴.۲.۳ گام چهارم: پیش‌پردازش و پاک‌سازی (فصل ۲، ۱۵ نمره)

۱. ستون `addr:city` را نرمال‌سازی کنید: حروف بزرگ و کوچک لاتین را یکی کنید، پیشوند «شهر» را حذف کنید، و برای دست‌کم ۱۰ شهر پرتکرار نام لاتین را به معادل فارسی‌اش نگاشت کنید. تعداد مقادیر یکتا را قبل و بعد از این کار مقایسه کنید.

۲. تابعی بنویسید که مقدار `capacity` را به عدد صحیح تبدیل کند، از جمله تبدیل ارقام فارسی به لاتین؛ هر مقداری که منطقاً قابل تبدیل نیست را `NaN` بگذارید و تعداد رکوردهایی که این‌طور شده‌اند را گزارش دهید.

۳. ارقام فارسی و لاتین ستون `phone` را یک‌دست کنید (همه به لاتین) و یک قاعده‌ی ساده برای

«شماره‌ی احتمالاً نامعتبر» تعریف کنید، مثلاً کمتر از ۸ رقم. گزارش دهید چند مورد این قاعده را نقض می‌کنند.

۵.۲.۳ گام پنجم: شباهت و فاصله (فصل ۲، ۲۰ نمره)

۱. از بین کاندیدهای رکورد تکراری که در گام سوم پیدا کردید، حداقل ۲۰ جفتی را انتخاب کنید که هر دو عضوشان ستون `name` پر دارند. برای هر جفت، شباهت Jaccard را بین مجموعه‌کلیدهای `other_tags` دو عضو حساب کنید. فرمول Jaccard را خودتان با عملیات مجموعه در پایتون بنویسید؛ استفاده از تابع آماده‌ی کتابخانه برای همین محاسبه پذیرفته نیست.

۲. حالا نام‌های همان جفت‌ها را هم با همین فرمول Jaccard مقایسه کنید، با این تفاوت که این‌بار به‌جای مجموعه‌کلیدهای تگ، مجموعه‌ی کلمات هر نام را می‌سازید؛ یعنی هر نام را از روی فاصله به کلمه‌هایش می‌شکنید (مثلاً «بانک ملی» می‌شود مجموعه‌ی دوعضوی «بانک» و «ملی») و شباهت را روی همین دو مجموعه حساب می‌کنید. آیا جفت‌هایی که شباهت تگ‌شان بالاست، شباهت نامشان هم بالاست؟ یک جفت پیدا کنید که این دو معیار درباره‌اش توافق ندارند (مثلاً تگ‌ها شبیه‌اند ولی نام‌ها فرق دارند، یا برعکس) و دلیلش را بررسی کنید.

۳. بر اساس این دو معیار، آستانه‌ای پیشنهاد دهید که بالاترش دو رکورد را «به احتمال زیاد یک مکان واقعی» حساب کند. با این آستانه چند جفت را در نهایت تکراری علامت می‌زنید؟

۶.۲.۳ گام ششم: آمار توصیفی، تجسم و OLAP (فصل ۳، ۲۰ نمره)

۱. فراوانی و مد `main_value` را درون هر `main_key` گزارش دهید؛ مثلاً پرتکرارترین نوع amenity کدام است؟

۲. صدک‌های ۲۵، ۵۰، ۷۵ و ۹۰ ستون `hub_km` را حساب کنید. چند درصد رکوردها بیش از ۳۰۰ کیلومتر از نزدیک‌ترین مرکز استانی تقریبی‌شان فاصله دارند، و این مکان‌ها بیشتر کجای کشورند؟

۳. دو نمودار رسم کنید: یکی هیستوگرام سال ثبت (`edit_date`)، که روند رشد پوشش OSM در ایران طی سال‌ها را نشان دهد، و یکی باکس‌پلات `hub_km` به تفکیک پنج `nearest_hub` پرتکرار.

۴. یک دیتاکیوب با سه بُعد `nearest_hub`، `main_key` و سالِ `edit_date` بسازید که مقدار هر سلولش تعداد رکورد باشد. سپس روی همین دیتاکیوب سه عملیات زیر را انجام دهید و برای هرکدام یک جمله بنویسید که چه سوالی را جواب داد:

- یک `roll-up`: بُعد سال را حذف کنید و فقط جمع کل رکوردها را بر اساس شهر و دسته نگه دارید.
- یک `drill-down`: برای یک شهر و دسته‌ی مشخص (مثلاً leisure در تهران)، به سطح جزئی‌تر `main_value` بروید و ببینید این دسته از چه زیردسته‌هایی تشکیل شده.
- یک `Selection` به سبک فصل ۳: فقط رکوردهای تهران را نگه دارید و توزیع دسته‌ها را درون همان یک شهر گزارش دهید.